

UNIVERSIDADE TECNOLÓGICA FEDERAL DO PARANÁ

ARNOLD ZAGO DOS REIS

USO DE DISPOSITIVOS COMPACTOS PARA DETECÇÃO
COMPORTAMENTAL DE BOVINOS

DOIS VIZINHOS

2026

ARNOLD ZAGO DOS REIS

USO DE DISPOSITIVOS COMPACTOS PARA DETECÇÃO
COMPORTAMENTAL DE BOVINOS

Use of compact devices for behavioral detection of cattle

Trabalho de Conclusão de Curso de Graduação
apresentado como requisito parcial para a
obtenção do título de Bacharel em Engenharia
de Software, Universidade Tecnológica Federal
do Paraná (UTFPR).

Orientador(a): Prof. Dr. Marlon Marcon

DOIS VIZINHOS

2026



Esta licença permite remixe, adaptação e criação a partir do trabalho, para fins não comerciais, desde que sejam atribuídos créditos ao(s) autor(es). Conteúdos elaborados por terceiros, citados e referenciados nesta obra não são cobertos pela licença.

ARNOLD ZAGO DOS REIS

USO DE DISPOSITIVOS COMPACTOS PARA DETECÇÃO
COMPORTAMENTAL DE BOVINOS

Trabalho de Conclusão de Curso de Graduação
apresentado como requisito para obtenção do
título de Bacharel em Engenharia de Software,
Universidade Tecnológica Federal do Paraná
(UTFPR).

Data de aprovação: 30 de Junho de 2025

Marlon Marcon
Doutorado
Universidade Tecnológica Federal do Paraná - Câmpus Dois Vizinhos ,

Andre Roberto Ortoncelli
Doutorado
Universidade Tecnológica Federal do Paraná - Câmpus Dois Vizinhos

Evandro Miguel Kuszera
Doutorado
Universidade Tecnológica Federal do Paraná - Câmpus Dois Vizinhos

DOIS VIZINHOS

2026

RESUMO

A detecção precisa de bovinos é fundamental para a eficiência produtiva e gestão sustentável na pecuária. Os métodos tradicionais de monitoramento desses animais, geralmente por observação humana, são limitados e estão suscetíveis a erros. Este trabalho teve como objetivo aplicar o uso de dispositivos compactos, conhecidos como *Single Board Computers*, integrados com algoritmos de visão computacional, especificamente o YOLO, para viabilizar a detecção automatizada de bovinos. Foram testados diferentes tipos de SBCs, com diferentes técnicas de detecção de objetos, comparando a precisão na detecção de comportamentos, tempo de processamento e a estabilidade operacional. Os resultados demonstram a compatibilidade dos SBCs com os modelos, eficiência no processamento em tempo real, sendo esses dispositivos adequados para aplicação em ambientes rurais.

Palavras-chave: Visão Computacional; Detecção de Objetos; Single Board Computers; Análise Comportamental; Pecuária de Precisão; YOLO; Monitoramento Automatizado; Dispositivos Compactos.

ABSTRACT

Accurate cattle detection is essential for productive efficiency and sustainable management in livestock farming. Traditional methods of monitoring these animals, typically through human observation, are limited and prone to errors. This study aimed to apply the use of compact devices, known as Single Board Computers, integrated with computer vision algorithms—specifically YOLO—to enable automated cattle detection. Different types of SBCs were tested alongside various object detection techniques, comparing behavior detection accuracy, processing time, and operational stability. The results demonstrate the compatibility of SBCs with the models and their efficiency in real-time processing, indicating that these devices are suitable for use in rural environments.

Keywords: Computer Vision; Object Detection; Single Board Computers; Behavioral Analysis; Precision Livestock Farming; YOLO; Automated Monitoring; Compact Devices.

SUMÁRIO

1	Introdução	4
2	Referencial teórico	5
2.1	Dispositivos de Baixo Custo no Reconhecimento de Padrões Visuais	5
2.2	Deteccção de objeto	6
2.3	YOLO (<i>You Only Look Once</i>).....	7
2.4	Nanodet	7
2.5	DETR	8
3	Metodologia	8
3.1	Seleção dos SBCs.....	9
3.2	Teste dos modelos de detecção	9
3.3	Configuração dos SBC	9
3.3.1	Raspberry Pi Zero	9
3.3.2	Banana Pi m2 Zero	10
3.3.3	Raspberry Pi 3	10
3.3.4	Jetson Nano	11
3.4	Compatibilidade do SBC com os modelos de detecção de objetos	11
3.5	Testes nas plataformas que atenderam aos requisitos	12
3.5.1	Protocolo Experimental	12
4	Resultados	13
5	Conclusões	15
6	Trabalhos futuros.....	16

Uso de Dispositivos Compactos para Detecção Comportamental de Bovinos

ARNOLD ZAGO DOS REIS

¹UNIVERSIDADE TECNOLÓGICA FEDERAL DO PARANÁ

Campus Dois Vizinhos

arnold@alunos.utfpr.edu.br

Abstract. *Accurate cattle detection is essential for productive efficiency and sustainable management in livestock farming. Traditional methods of monitoring these animals, typically through human observation, are limited and prone to errors. This study aimed to apply the use of compact devices, known as Single Board Computers, integrated with computer vision algorithms—specifically YOLO—to enable automated cattle detection. Different types of SBCs were tested alongside various object detection techniques, comparing behavior detection accuracy, processing time, and operational stability. The results demonstrate the compatibility of SBCs with the models and their efficiency in real-time processing, indicating that these devices are suitable for use in rural environments.*

Resumo. *A detecção precisa de bovinos é fundamental para a eficiência produtiva e gestão sustentável na pecuária. Os métodos tradicionais de monitoramento desses animais, geralmente por observação humana, são limitados e estão suscetíveis a erros. Este trabalho teve como objetivo aplicar o uso de dispositivos compactos, conhecidos como Single Board Computers, integrados com algoritmos de visão computacional, especificamente o YOLO, para viabilizar a detecção automatizada de bovinos. Foram testados diferentes tipos de SBCs, com diferentes técnicas de detecção de objetos, comparando a precisão na detecção de comportamentos, tempo de processamento e a estabilidade operacional. Os resultados demonstram a compatibilidade dos SBCs com os modelos, eficiência no processamento em tempo real, sendo esses dispositivos adequados para aplicação em ambientes rurais.*

1. Introdução

A detecção precisa e monitoramento de bovinos possuem grande importância em diversos campos de estudo, cobrindo uma ampla quantidade de disciplinas, como a Biologia, Ecologia e Zootecnia. A capacidade de identificar e localizar animais automaticamente serve como base para aplicações secundárias como a análise comportamental, promovendo melhorias na saúde, bem-estar e até na conservação de espécies animais. No passado, essas tarefas eram feitas de forma manual e dependiam das análises diretas feitas pelo humano e, com isso, poderiam proporcionar erros, além de demandar longos períodos de observação direta. Entretanto, os avanços tecnológicos dos últimos anos, em relação à visão computacional, vêm gerando novas oportunidades e possibilidades de evolução dos métodos de análise, para automatizá-la, resultando em uma maior precisão e eficiência [Rodriguez-Baena et al. 2020].

A visão computacional, subárea da Inteligência Artificial (IA), vem evoluindo significativamente. Com esses avanços, favorece a criação de sistemas capazes de entender e interpretar

grandes volumes de imagens e dados de forma precisa e rápida. Atualmente, vem proporcionando novas oportunidades de automatizar e melhorar a precisão e eficiência dos métodos de análise em imagens, como o comportamental. A demanda pela automatização de diversos processos de identificação dos animais vem crescendo com o passar do tempo, levando à utilização de dispositivos embarcados e métodos de reconhecimento, que vêm desempenhando um papel crucial nos processos [Chen et al. 2024].

Esses dispositivos portáteis possuem baixo custo. Porém, apesar de permitirem a implementação de sistemas de visão computacional, a infraestrutura, como conexão com a internet e poder de processamento, pode se tornar empecilhos à utilização dos mesmos [Soares et al. 2024].

O uso desses dispositivos compactos pode oferecer um monitoramento em diversos tipos de cenários e ambientes de baixo custo, sendo ideais para áreas rurais e remotas. Este trabalho busca avaliar a aplicabilidade de sistemas de detecção de objetos, tais como o YOLO [Redmon 2016], em SBCs, e com isso, possibilitar a captura de padrões comportamentais. Com base nisso, combinar visão computacional com dispositivos compactos pode facilitar o monitoramento e a gestão sustentável dos animais, contribuindo para avanços da ciência para o bem-estar e conservação dos animais [Puglia 2023].

Desta forma, este trabalho propõe-se a investigar a viabilidade e a eficácia da aplicação de algoritmos de detecção de objetos baseados em *Deep Learning*, como o YOLO, em SBCs para o monitoramento automatizado de bovinos. Foram avaliados o desempenho de diferentes combinações de hardware e software em termos de precisão e velocidade de processamento em cenários que simulam o ambiente rural para bovinos confinados. O objetivo foi avaliar o potencial de desenvolvimento de uma solução de baixo custo e alta eficiência, que viabilize a análise comportamental em tempo real, o que contribui para a gestão sustentável e o bem-estar animal na pecuária moderna.

2. Referencial teórico

2.1. Dispositivos de Baixo Custo no Reconhecimento de Padrões Visuais

Esta seção apresenta os dispositivos que foram utilizados no presente trabalho para a aplicação de análise de comportamento animal, os *Single Board Computers* (SBC). Os SBCs são dispositivos de baixo custo que são semelhantes a um computador básico, com a diferença de que todos os componentes são integrados em uma única placa, ao contrário de um computador tradicional que, em sua maior parte, é modular por natureza. O que chama a atenção nesses dispositivos são seus tamanhos, pois a maioria dos SBCs são do tamanho de um cartão de crédito ou, às vezes, até menor [Andrei et al. 2020].

Os SBC mais conhecidos atualmente e que serão utilizados neste projeto são os da Raspberry, sendo eles Raspberry Pi 3, Raspberry Pi Zero, e outros como o Banana Pi m2 Zero e NVIDIA Jetson Nano, tendo vários outros modelos diferentes, cada um com suas capacidades de processamento e design diferentes. A seguir, estes SBCs são descritos, e a Tabela 1 apresenta um comparativo entre eles.

Raspberry Pi 3: É uma das placas da linha Raspberry, indicada para aplicações que exigem conectividade e desempenho equilibrado. Conta com um processador Broadcom BCM2837 (ARM Cortex-A53 de 64 bits) quad-core de 1,2GHz, acompanhado por 1GB de memória RAM. Possui conectividade integrada com Wi-Fi e Bluetooth 4.1, quatro portas USB 2.0, 1 porta HDMI e uma interface Ethernet gigabit. Seu valor é aproximadamente de 35 dólares [Upton and Halfacree 2016].

Raspberry Pi zero: É um dos SBCs mais econômicos, com um processador ARM1176JZF-S de 1 GHz, possui 1 porta mini HDMI e 1 porta micro USB. Ele foi projetado para projetos simples e de baixo custo, sendo ideal para projetos compactos que sejam menos exigentes, dispositivos IoT e aplicações com demandas leves de processamento. Seu valor tem um preço médio de 10 dólares [Upton and Halfacree 2016].

Banana Pi m2 Zero: É uma alternativa do Raspberry Pi Zero, mas tem uma capacidade de processamento e conectividade maior, tem um processador Allwinner H2, Quad-core Cortex-A7 de 1 GHz, também possui 512 MB de RAM. O Banana Pi é ideal para projetos que exigem um maior processamento que o Raspberry Pi Zero [Banana Pi 2025].

NVIDIA Jetson Nano: É um SBC da NVIDIA voltado para aplicações de IA, visão computacional e robótica embarcada. Ele possui um processador Quad-core Cortex-A57 1,4 GHz, com uma GPU Maxwell com 128 CUDA cores e 4 GB de RAM LPDDR4. Conta com quatro portas USB, Ethernet Gigabit, saídas HDMI e DP. Seu valor varia entre 100 e 130 dólares [NVIDIA 2019].

Table 1. Comparativo dos SBCs em função do Processador, RAM, GPU e Custo.

Modelos	Processador	RAM	GPU	Custo(US\$)
Raspberry Pi 3	ARM Cortex-A53 1,2GHz	1 GB	Não	35
Raspberry Pi zero	ARM1176JZF-S, 1 GHz	512 MB	Não	10
Banana Pi m2 Zero	Allwinner H2+, quad-core Cortex-A7, 1 GHz	512 MB	Não	15
NVIDIA Jetson Nano	ARM Cortex-A57 1,4 GHz	4 GB	Sim	100-130

2.2. Detecção de objeto

A detecção de objetos é uma área fundamental da visão computacional que visa identificar e localizar objetos específicos dentro de uma imagem ou sequência de vídeo. Atualmente, o avanço de tecnologias de visão computacional possibilitou uma melhora no gerenciamento com precisão de gado, como a detecção de doenças, monitoramento de saúde e bem-estar do animal [Hossain et al. 2022]. Neste trabalho, foram explorados os detectores YOLO [Redmon 2016] v4 e v7 em suas versões tiny, DETR [Rustamy 2023b] e NanoDet [RangiLyu 2021], todos indicados para aplicações em tempo real.

Trabalhos como o de [Nasir et al. 2023], apresentam soluções baseadas em *deep learning*, mas são utilizados apenas um ângulo de imagem para realizar a detecção. Como pode ser visto na Figura 1, a limitação do ângulo pode comprometer a eficiência da análise de comportamento, devido à sobreposição dos animais.




Figure 1. Detecção e reconhecimento comportamental de gado confinado. [Nasir et al. 2023]

2.3. YOLO (You Only Look Once)

O algoritmo YOLO é demonstrado como uma abordagem para a detecção de objetos em tempo real que é bastante conhecida por sua velocidade e precisão. Ao contrário dos outros detectores, que dependem da análise de múltiplas regiões da imagem, como o Faster R-CNN, o YOLO utiliza uma única rede neural, permitindo que a rede processe a imagem e preveja todas as caixas delimitadoras simultaneamente. [Redmon 2016]

Uma vantagem do YOLO apresentada por [Redmon 2016], seria a sua alta capacidade de generalização. Essa característica torna com que o algoritmo seja menos propenso a erros ou falhas em cenários inesperados ou novos domínios de aplicação, graças à utilização de uma arquitetura de rede neural profunda capaz de aprender recursos de alto nível [Freitas 2024].




Figure 2. Processo de previsão do YOLO [Redmon 2016]

A Figura 2 ilustra seu processo em três etapas essenciais:

1. **Divisão da imagem em grade:** responsável pelo redimensionamento da imagem para um tamanho padrão;
2. **Extração de características via rede convolucional:** etapa na qual a imagem passa pela rede neural convolucional, que analisa os padrões e as características do objeto;
3. **Supressão não-máxima (NMS):** responsável pela Supressão não-maxima para filtrar detecções redundantes.

2.4. Nanodet

O Nanodet é um modelo de detecção de objetos leve e eficiente, proposto por [RangiLyu 2021], que foi projetado também para dispositivos com limitações em seus recursos computacionais como SBCs e outros dispositivos móveis. [Miao et al. 2023] Diferentemente dos modelos tradicionais baseados em âncoras e NMS (Non-Maximum Suppression), o Nanodet elimina ambas as etapas e adota uma abordagem sem âncora, o que reduz a complexidade computacional e o consumo de memória. [RangiLyu 2021]

O fluxo do NanoDet, conforme ilustrado na Figura 3, opera através dos seguintes componentes:




Figure 3. Processo do Nanodet [RangiLyu 2021]

1. **Backbone (Extração de Características):** O backbone, que é baseado no ShuffleNetV2, processa a imagem de entrada gerando mapas de características multi-escala. Essas características são então passadas para o PAFPN.
2. **PAFPN (Path Aggregation Feature Pyramid Network):** O PAFPN realiza a fusão multiescala das características, combinando características de diferentes níveis hierárquicos do Backbone(ShuffleNetV2), para enriquecer a representação espacial e semântica.
3. **Prediction Heads (Saída):** Os Prediction Heads são responsáveis por gerar as saídas finais de classificação e localização dos objetos.

2.5. DETR

O DETR (DEtection TRansformer) é um modelo de detecção de objetos novo, introduzido em 2020 por pesquisadores da Facebook AI Research (FAIR). Ele utiliza a arquitetura de *transformers*, que originalmente foi desenvolvida para processamento de linguagem natural. O DetR, diferentemente dos outros modelos, é um modelo de predição direta, utilizando uma arquitetura de codificador-decodificador para prever todos os objetos de forma simultânea. Sendo uma abordagem mais simples e eficiente, se comparado aos detectores de objetos tradicionais [Rustamy 2023a].

A arquitetura do DETR consiste em três componentes principais, conforme ilustrado na figura 4:




Figure 4. Processo do Detr [Rustamy 2023b]

1. **Backbone (Extração de Recursos):** O Backbone CNN(ResNet), processa a imagem de entrada e gera um mapa de ativação, passando as características para o transformador codificador-decodificador. [Rustamy 2023a]
2. **Transformador codificador:** Nessa etapa o codificador recebe as características do mapa, primeiramente o codificador reduz a dimensão de características e aplica redes de auto-atenção e alimentação [Zhu et al. 2021]
3. **Transformador decodificador:** Então decodificador recebe os vetores posicionais aprendidos, gera as detecções finais de saída, onde de forma independente, prevê as coordenadas de caixa e rótulos de classe. [Rustamy 2023a]

3. Metodologia

Nesta seção será apresentada a metodologia, desenvolvida a partir do trabalho proposto por [Freitas 2024], avaliando a compatibilidade com os dispositivos SBCs (*Single Board Computer*). O objetivo principal foi avaliar como esses dispositivos se comportam ao executar os modelos de detecção de objetos e, após isso, foram feitos testes com detecção de comportamento.

No trabalho realizado por [Freitas 2024], foi realizada uma análise comportamental dos bovinos utilizando as versões recentes do YOLO, como o YOLOv8 e o YOLOv9, utilizando classes como Bebendo, Comendo, Deitado, Em Pé, Escondido, Pastando e Outro. As etapas da metodologia são descritas nas seções a seguir.

3.1. Seleção dos SBCs

Primeiramente, foi realizada uma seleção e organização de quais dispositivos SBCs(*Single Board Computers*) foram testados para os testes. A escolha considerou os modelos mais conhecidos, como o Raspberry Pi, e outros dispositivos similares a ele, priorizando aqueles que oferecem suporte a bibliotecas de visão computacional. Foram selecionados quatro modelos:

- **Raspberry Pi Zero:** CPU ARM1176JZF-S, 512MB RAM;
- **Banana Pi M2 Zero:** CPU quad-core ARM Cortex-A7, 512MB RAM;
- **Raspberry Pi 3 Model B:** CPU quad-core ARM Cortex-A53, 1GB RAM;
- **NVIDIA Jetson Nano:** GPU Maxwell 128 cores, CPU quad-core ARM A57, 4GB RAM.

3.2. Teste dos modelos de detecção

Os modelos utilizados por [Freitas 2024] foram analisados inicialmente e aplicados em um ambiente de teste controlado, para avaliar sua funcionalidade e desempenho em relação à detecção de bovinos e detecção comportamental dos animais. Esta etapa identificou os possíveis ajustes necessários nos modelos e o surgimento de novos modelos, antes da implementação nos SBCs. Nas subseções a seguir, são apresentados os modelos adotados neste trabalho.

A partir dessa análise, foi escolhido os seguintes modelos de detecção:

- **YOLOv4-tiny**
- **YOLOv7-tiny**
- **Nanodet**
- **DETR**

3.3. Configuração dos SBC

Após a seleção dos SBCs e os testes dos modelos, os SBCs foram configurados para suportar os modelos que incluem a instalação de sistemas operacionais, bibliotecas de visão computacional como o YOLO e outras bibliotecas que foram requisitadas de acordo com cada modelo de detecção. A seguir, é relatado o processo de configuração de cada SBC utilizado no presente trabalho.

3.3.1. Raspberry Pi Zero

O Raspberry Pi Zero foi configurado com o Sistema Operacional Raspberry Pi OS. Para a utilização do dispositivo, foi necessário um hub USB para expandir as portas, adaptador mini HDMI para HDMI, conversor de micro USB para USB padrão, um mini adaptador USB para Wi-Fi, além de teclado e mouse USB. A Figura 5 ilustra o equipamento utilizado e a Figura 6 apresenta o dispositivo Raspberry Pi Zero utilizado.



Figure 5. Hub USB para expandir as portas, adaptador micro HDMI, adaptador micro USB para USB e adaptador USB para WIFI



Figure 6. Raspberry Pi Zero

3.3.2. Banana Pi m2 Zero

O Banana Pi M2 Zero foi configurado com o Sistema Operacional baseado em Armbian (Debian) com kernel Linux 5.15, disponibilizado por [Qengineering 2023], que inclui suporte nativo para a câmera OV5640 e otimizações para o hardware do Banana Pi M2 Zero. As bibliotecas instaladas incluem OpenCV 4.5.5. Para a utilização do dispositivo, foi necessário um hub USB para expandir as portas, adaptador mini HDMI para HDMI, conversor de micro USB para USB padrão, um mini adaptador USB para Wi-Fi, além de teclado e mouse USB. A Figura 5 ilustra o equipamento utilizado e a Figura 7 ilustra o visual do Banana Pi M2 Zero.



Figure 7. Banana Pi M2 Zero (imagem da esquerda rotacionada)

3.3.3. Raspberry Pi 3

O Raspberry Pi 3 Model B utilizou o sistema operacional Raspberry Pi OS (64-bit) com kernel otimizado. As bibliotecas instaladas incluirão OpenCV (versão 4.5.5). Para utilizar o dispositivo, é necessário periféricos básicos como: um teclado e um mouse com conexão USB. O dispositivo oferece suporte a conectividade sem fio e com cabo Ethernet, além de contar com quatro portas USB para conexão de dispositivos externos. A alimentação do SBC é fornecida

por meio de uma porta micro USB designada para energia (fonte 5V/2.5A), a saída de vídeo é localizada pela porta HDMI disponível. A Figura 8 ilustra o visual do Raspberry Pi 3.



Figure 8. Raspberry Pi 3

3.3.4. Jetson Nano

O NVIDIA Jetson Nano foi configurado com o sistema operacional JetPack SDK (versão 4.6), que inclui suporte nativo para CUDA, cuDNN e TensorRT. A biblioteca OpenCV foi instalada com suporte a GPU. Para utilizar o dispositivo, é necessário periféricos básicos como: um teclado e um mouse com conexão USB. O Jetson Nano não possui suporte para conectividade sem fio, requerendo obrigatoriamente conexão física via cabo Ethernet para acesso à rede. O dispositivo oferece quatro portas USB para conexão de dispositivos externos, saída de vídeo HDMI e alimentação através de conector barrel jack (5V/4A) e conector micro USB como os outros SBCs. A Figura 9 ilustra o visual do NVIDIA Jetson Nano.



Figure 9. NVIDIA Jetson Nano

3.4. Compatibilidade do SBC com os modelos de detecção de objetos

Está etapa se mostrou uma das centrais, na qual, foi verificada a compatibilidade dos dispositivos (SBCs) com os modelos testados. Foram realizados testes iniciais para confirmar e validar que os SBCs podem executar os modelos sem que ocorra um comprometimento significativo de desempenho. Esses testes foram:

1. **Suporte a bibliotecas/dependências:** Verificação da compatibilidade das bibliotecas (PyTorch, OpenCV) e com arquiteturas ARMv7/ARMv8.
2. **Execução básica:** Testes de inferência inicial para confirmar a capacidade de carregamento e execução dos modelos sem falhas críticas (ex: alocação de memória, desligamento inesperado do dispositivo).

3. **Degradação controlada:** Avaliação de que eventuais perdas de desempenho mantiveram-se dentro de limites operacionais aceitáveis (latência < 30s/inferência, consumo de memória < 80% da capacidade).

Os principais desafios identificados foram:

1. **Desligamento Inesperado:** Assim que começava a instalar as bibliotecas/dependências no Raspberry Pi Zero, ele apresentou falhas e desligamento do dispositivo, impossibilitando o avanço para os testes dos modelos.
2. **Incompatibilidade do modelo DETR com os dispositivos de recursos limitado:** Os SBCs Banana Pi M2 Zero e Raspberry Pi 3 não são compatíveis com as versões das bibliotecas requeridas pelo modelo.

3.5. Testes nas plataformas que atenderam aos requisitos

Por fim, os dispositivos e modelos que passaram das etapas anteriores foram submetidos a testes práticos, na qual incluirão a execução dos modelos em cenários simulados e sua medição de desempenho foi separada em:

1. **Desempenho do tempo médio por imagem:** Mensurado com base em:
 - Latência média por inferência (segundos)
2. **Estabilidade operacional:** Monitorada através de:
 - Consumo médio de memória RAM (% da capacidade)
 - Utilização média da CPU (% dos núcleos)
3. **Precisão dos Resultados:** Avaliada através das métricas padrão da visão computacional:
 - *Precision*: $\frac{TP}{TP+FP}$ (exatidão das detecções positivas)
 - *Recall*: $\frac{TP}{TP+FN}$ (capacidade de detectar todos os objetos)
 - *F1-Score*: $2 \times \frac{Precision \times Recall}{Precision + Recall}$ (média harmônica balanceada)

3.5.1. Protocolo Experimental

Os testes seguiram 2 protocolos, um desses protocolos obteve os dados de desempenho de tempo médio por imagem e a estabilidade operacional, utilizando o primeiro dataset retirado do Roboflow [Ioliktry 2023] que seria o teste de detecção de bovinos. Já o segundo protocolo foi realizado o teste de precisão na detecção de comportamento dos bovinos, onde foi utilizado um segundo dataset [de Animais em Confinamento 2024] para obter as métricas de precisão na detecção dos comportamentos dos bovinos. Os dois protocolos foram realizados para garantir comparabilidade:

1. **Teste de detecção de bovinos:**
 - **Dataset:** 115 imagens de bovinos em diferentes localidades.
 - **Repetições:** 5 execuções completas por modelo em cada dispositivo.
 - **Monitoramento:** Uso do Sysstat para o monitoramento de desempenho do CPU e Memória RAM, e Procs para o monitoramento do tempo medio por imagem.
 - **Local do Dataset:** Roboflow [Ioliktry 2023].
2. **Teste de Precisão na detecção de comportamento dos bovinos:**
 - **Dataset:** 288 imagens de bovinos confinados em diferentes posturas.
 - **Classes:** Bebendo, Comendo, Deitado, Em Pé, Escondido, Pastando e Outro.
 - **Monitoramento:** Uso do Colab PRO para treino dos modelos.
 - **Local do Dataset:** Roboflow [de Animais em Confinamento 2024].

4. Resultados

Os experimentos avaliaram o desempenho de quatro modelos de detecção, sendo eles, YOLOv4-tiny, YOLOv7-tiny, Nanodet e Detr em três SBCs diferentes (Banana Pi m2 Zero, Raspberry Pi 3 e NVIDIA Jetson Nano). Os testes iniciais foram feitos no dataset contendo 115 imagens que foi explicado na seção 3.5 com foco em analisar o desempenho de cada SBC, pegando o tempo médio por imagem de cada um desses SBCs com seus respectivos modelos de detecção de objetos.

Algumas imagens do dataset são ilustradas na Figura 10:



Figure 10. Imagens dos bovinos no Roboflow [Ioliktry 2023]

A Tabela 2 resume os resultados de velocidade de processamento:

Table 2. Desempenho do tempo médio por imagem (segundos)			
Modelo	Banana Pi M2 Zero	Raspberry Pi 3	NVIDIA Jetson Nano
YOLOv4-TINY	21,59	24,50	5,86
YOLOv7-TINY	21,60	20,65	6,69
NanoDet	4,00	4,80	1,44
DETR	-	-	1,45

O Jetson Nano apresentou superioridade geral dos modelos, especialmente com modelos que aproveitam sua GPU. Mas, com base na capacidade dos outros SBCs, destaca-se o modelo Nanodet, que teve um tempo de 4 segundos por imagem para os SBCs que não possuem GPU e 1,4 segundos para o Jetson Nano, que possui GPU.

A Tabela 3 detalha o consumo de CPU e memória RAM durante a inferência. Observe:

Table 3. Estabilidade Operacional: Consumo de Recursos por Modelo e Plataforma				
Modelo	Recurso	Banana Pi M2 Zero	Raspberry Pi 3	NVIDIA Jetson Nano
YOLOv4-TINY	CPU	19.60%	17.70%	18.00%
	Memória	0.34%	4.50%	3.64%
YOLOv7-TINY	CPU	20.42%	18.57%	18.00%
	Memória	0.32%	4.87%	3.07%
NanoDet	CPU	21.00%	19.03%	18.00%
	Memória	0.22%	4.19%	4.24%
DETR	CPU	—	—	43.05%
	Memória	—	—	9.29%

Todos os SBCs apresentaram uma estabilidade operacional boa em relação ao consumo de CPU, apenas o DETR utilizado no NVIDIA Jetson Nano apresentou uma disparidade de 43% de consumo de CPU e 9,3% de memória.

Os outros dispositivos se mantiveram no consumo de CPU entre 17% a 21%, levando em consideração todos os modelos de detecção. Já a memória RAM, também levando em consideração todos os modelos, teve uma diferença significativa do Banana Pi m2 Zero para o Raspberry Pi 3, enquanto o Banana Pi consumiu entre 0,2-0,35% de memória RAM, o Raspberry Pi 3 ficou entre 4,2-4,9% de consumo de memória, indicando que o Banana Pi tem uma maior eficiência de memória se comparado ao Raspberry Pi 3.

Após serem realizados os testes de desempenho de tempo por imagem e os testes para analisar a estabilidade operacional, seguimos para o próximo teste em que foi utilizado o segundo dataset [de Animais em Confinamento 2024] para separar as métricas de precisão de cada modelo. Vale ressaltar que a precisão dos modelos não interfere no desempenho dos SBCs.

A Figura 11 ilustra algumas imagens utilizadas para treinamento de detecção comportamental dos bovinos:



Figure 11. Imagens dos bovinos no Roboflow [de Animais em Confinamento 2024]

A tabela 4 demonstra as Precision, Recall e F1-Score de cada classe presente no dataset [de Animais em Confinamento 2024], algumas classes não tiveram anotações o suficiente, como o 'Outro' e 'Bebendo', tendo uma diferença de alguns casos na métrica de precisão.

Classe	YOLOv4-tiny			YOLOv7-tiny			NanoDet			DETR		
	P	R	F1	P	R	F1	P	R	F1	P	R	F1
Bebendo	1.000	0.92	0.958	1.000	0.69	0.817	N/A	N/A	N/A	N/A	N/A	N/A
Comendo	0.938	0.92	0.929	0.434	0.69	0.533	0.902	0.68	0.776	1.000	0.69	0.817
Deitado	0.983	0.92	0.951	0.974	0.69	0.808	0.967	0.68	0.798	0.990	0.69	0.812
Em pé	0.925	0.92	0.922	0.867	0.69	0.769	0.825	0.68	0.746	0.940	0.69	0.793
Escondido	0.889	0.92	0.904	0.734	0.69	0.711	0.526	0.68	0.593	0.850	0.69	0.763
Pastando	0.907	0.92	0.913	0.417	0.69	0.520	0.568	0.68	0.620	0.550	0.69	0.613
Outro	1.000	0.92	0.958	N/A	N/A	N/A	N/A	N/A	N/A	N/A	N/A	N/A


A Tabela 5 compara as métricas de precisão geral dos modelos para a detecção comportamental dos bovinos:

Table 5. Métricas

Métrica	Yolov4-tiny	Yolov7-tiny	NanoDet	DETR
Precision	0,96	0,91	0,76	0,94
Recall	0,92	0,69	0,68	0,69
F1 Score	0,94	0,78	0,72	0,79

Estas métricas foram calculadas com base na média de todas as classes. O YOLOv4-tiny obteve o melhor desempenho geral, com uma Precision de 0.96, indicando uma proporção maior de verdadeiros positivos entre todos os exemplos identificados como positivos. O Recall de 0.92 revelou uma capacidade superior de identificar verdadeiros positivos entre todos os positivos presentes. O F1-Score de 0.94, sendo a média harmônica entre Precision e Recall, confirma a superioridade em eficiência do YOLOv4-tiny em relação aos demais.

As métricas de Precision, Recall e F1-Score são iguais para todos os dispositivos que utilizarem esses modelos de detecção, tanto em dispositivos com alta capacidade operacional quanto em dispositivos com recursos limitados. A Figura 12 demonstra a detecção dos modelos testados.



(a) YOLOv4-tiny



(b) YOLOv7-tiny



(c) Nanodet



(d) DETR

Figure 12. Comparação do resultado da detecção de objetos entre diferentes modelos.

5. Conclusões

O trabalho focou em avaliar a aplicabilidade de detecção de objetos e detecção comportamental dos bovinos confinados em *Single Board Computers* (SBCs). Os resultados comprovam que os SBCs, como o Banana Pi M2 Zero, o Raspberry Pi 3 e o NVIDIA Jetson Nano, são capazes de executar modelos modernos de detecção de objetos, apesar das diferenças significativas de desempenho com base nos modelos e na capacidade do hardware.

A utilização do Google Colab Pro proporcionou uma robusta infraestrutura, com as especificações adequadas para o treinamento de todos os modelos e ajudando a obter os dados do Precision, que mostrou a medição de previsões positivas, o Recall, que mede a capacidade do modelo de encontrar instâncias positivas e, por fim, o F1-Score, que é a média harmônica entre o Precision e o Recall de cada modelo de detecção de objeto.

O YOLOv4-tiny foi o modelo que destacou-se como o mais equilibrado, alcançando 0.94 de F1-Score, enquanto o Nanodet revelou-se como a solução mais eficiente para dispositivos com menos recursos computacionais, tendo em vista que foi o modelo com o tempo médio por imagem significativamente mais rápido se comparado aos outros modelos, ficando entre 1,4 e 4,8 segundos por imagem e o modelo mais estável em consumo operacional de memória RAM, mas o que mais consumiu CPU.

Quanto aos objetivos propostos, comprovou-se que SBCs podem utilizar modelos de visão computacional, porém com limitações operacionais, enquanto o NVIDIA Jetson Nano suportou todos os modelos testados, incluindo o complexo e mais recente DETR. Os SBCs como o Banana Pi e o Raspberry Pi 3 demonstraram restrições de compatibilidade com as dependências necessárias para o DETR, o que impediu a execução do DETR nesses dispositivos.

O YOLOv4-tiny no Jetson Nano tornou-se a melhor opção para cenários que demandam uma alta precisão de detecção e pouco tempo de execução, considerando os resultados obtidos como 0.94 de F1-Score e o tempo de inferência de 5,86 segundos por imagem. Em adição a isso, o Nanodet no Banana Pi ofereceu a opção eficiente para cenários em que os recursos operacionais são limitados e demandam pouco tempo para a execução, considerando o hardware presente no dispositivo, o baixo consumo de memória RAM de 0.22% e o tempo de inferência por imagem de 4 segundos.

No decorrer do trabalho, foram identificadas algumas limitações durante a pesquisa: a dependência de periféricos externos devido à escassez de portas, adaptadores de Wi-Fi, saída de imagem e micro-USB para USB em modelos como o Banana Pi e o Raspberry Pi Zero. Apesar disso, este trabalho evidenciou que dispositivos compactos de baixo custo, conhecidos como SBCs, integrados a algoritmos de visão computacional, são viáveis para revolucionar o monitoramento de bovinos, reduzindo custos operacionais e permitindo a coleta de dados.

6. Trabalhos futuros

Com base na realização deste trabalho, há diversas possibilidades que podem ser exploradas para aprofundar a aplicabilidade de detecção de objetos em dispositivos compactos. No contexto geral, um caminho para a continuidade é testar em outros tipos de SBCs, alguns mais recentes como o Raspberry Pi 5 ou dispositivos mais potentes para realizar o comparativo de desempenho e custo-benefício mais abrangente.

Em complemento, outro caminho que pode ser seguido é analisar outros tipos de modelos de detecção além dos já apresentados neste trabalho, podendo obter novos dados de desempenho ou novas métricas de Precision, Recall e F1-Score. Além disso, estudos futuros que podem complementar essa pesquisa seriam a implementação de uma detecção de comportamento mais aprofundada, como a identificação de doenças, feridas e outros comportamentos.

Para consolidar a aplicabilidade prática, etapas de validação em ambientes reais são imprescindíveis, sendo a implantação de protótipos em confinamentos sob variações climáticas e analisando como o dispositivo desempenha. Estas iniciativas, coletivamente, em ambientes reais, seriam o divisor de águas para transpor a fronteira entre a pesquisa acadêmica e a adoção no campo, transformando os desafios técnicos atuais em soluções que efetivamente simpli-

fiquem o dia a dia do produtor e elevem os padrões de bem-estar animal.

References

- [Andrei et al. 2020] Andrei, C.-C., Tudor, G., Arhip-Călin, M., Fierăscu, G., and Urcan, C. (2020). Raspberry pi, an alternative low-cost plc. In *2020 International Symposium on Fundamentals of Electrical Engineering (ISFEE)*, pages 1–6. IEEE.
- [Banana Pi 2025] Banana Pi, B. (2025). M2 zero-banana pi wiki.
- [Chen et al. 2024] Chen, Y., Jiao, T., Song, J., He, G., and Jin, Z. (2024). Ai-enabled animal behavior analysis with high usability: A case study on open-field experiments. *Applied Sciences*, 14(11):4583.
- [de Animais em Confinamento 2024] de Animais em Confinamento, A. C. (2024). Comportamento de gado dataset. [https://universe.roboflow.com/aplicao-de-tcnicas-de-viso-computacional-para-anlise-comportamental-comportamento-de-gado-axlhv/dataset/6](https://universe.roboflow.com/aplicao-de-tcnicas-de-viso-computacional-para-analise-comportamental-comportamento-de-gado-axlhv/dataset/6).
- [Freitas 2024] Freitas, V. d. A. (2024). Aplicação de técnicas de visão computacional para análise comportamental de animais em confinamento. Master's thesis, UTFPR.
- [Hossain et al. 2022] Hossain, M. E., Kabir, M. A., Zheng, L., Swain, D. L., McGrath, S., and Medway, J. (2022). A systematic review of machine learning techniques for cattle identification: Datasets, methods and future directions. *Artificial Intelligence in Agriculture*, 6:138–155.
- [loliktry 2023] loliktry (2023). Cattle detection dataset. https://universe.roboflow.com/loliktry/cattle_detection-060yo/dataset/1.
- [Miao et al. 2023] Miao, D., Wang, Y., Yang, L., and Wei, S. (2023). Foreign object detection method of conveyor belt based on improved nanodet. *IEEE Access*, 11:23046–23052.
- [Nasir et al. 2023] Nasir, M. F., Fuentes, A., Han, S., Park, J., Yoon, S., and Park, D. S. (2023). Cattle action recognition with multi-viewpoint cameras based on deep learning.
- [NVIDIA 2019] NVIDIA (2019). Jetson nano developer kit. Acessado em 15/05/2024.
- [Puglia 2023] Puglia, R. G. R. (2023). A aplicação de inteligência artificial no monitoramento comportamental de tamanduá-mirim (*tamandua tetradactyla*) e onça-pintada (*panthera onca*) ex situ.
- [Qengineering 2023] Qengineering (2023). Banana pi m2 zero with ov5640 camera. <https://github.com/Qengineering/BananaPi-M2-Zero-OV5640>. Acessado em: 01 Jan 2023.
- [RangiLyu 2021] RangiLyu (2021). Nanodet: Super fast and high accuracy lightweight anchor-free object detection model. <https://github.com/RangiLyu/nanodet>.
- [Redmon 2016] Redmon, J. (2016). You only look once: Unified, real-time object detection. In *Proceedings of the IEEE conference on computer vision and pattern recognition*.
- [Rodriguez-Baena et al. 2020] Rodriguez-Baena, D. S., Gomez-Vela, F. A., García-Torres, M., Divina, F., Barranco, C. D., Daz-Diaz, N., Jimenez, M., and Montalvo, G. (2020). Identifying livestock behavior patterns based on accelerometer dataset. *Journal of Computational Science*, 41:101076.

- [Rustamy 2023a] Rustamy, F. (2023a). DEtection TRansformer (DETR) vs. YOLO for object detection. <https://medium.com/@faheemrustamy/detection-transformer-detr-vs-yolo-for-object-detection-baeb3c50bc3>.
- [Rustamy 2023b] Rustamy, F. (2023b). DETR: Vision Transformers for Object Detection. <https://github.com/RustamyF/detr-vision>.
- [Soares et al. 2024] Soares, B., Silva, W. d. S., Ponciano, G., Lourenço, B., Almeida, V. d. L., Pastori, P. L., Magalhães, D., and Rocha, A. (2024). Embedded neural networks for identifying spodoptera frugiperda in corn plantations. In *Proceedings of 21st encontro nacional de inteligencia artificial e computacional (ENIAC)*.
- [Upton and Halfacree 2016] Upton, E. and Halfacree, G. (2016). *Raspberry Pi user guide*. John Wiley & Sons.
- [Zhu et al. 2021] Zhu, X., Su, W., Lu, L., Li, B., Wang, X., and Dai, J. (2021). Deformable detr: Deformable transformers for end-to-end object detection.